

颠覆机器，变幻莫测的身份：重新学习人类分类

克里斯蒂娜·卢*
christinalu@deepmind.com
深思
英国伦敦

杰基·凯*
kayj@deepmind.com
深思
英国伦敦

凯文·R·麦基
kevinrmckee@deepmind.com
深思
英国伦敦

抽象的

大多数与人类交互的机器学习系统都会构建某种形式的“身份”概念，然而人工智能研究的默认范式却将身份视为具有离散且静态的基本属性。与之形成鲜明对比的是，批判理论中的一些思想流派提出了一种可塑的、完全通过互动构建的身份概念；它是一种“行动”而非“存在”。本文旨在提炼这些思想，供机器学习从业者参考，并引入一种将身份视为自创生（autopoiesis）的理论，即身份形成和功能循环往复的过程。我们认为，由于缺乏对模型的迭代反馈，该领域使用的默认身份范式使现有的身份类别及其伴随的权力差异变得僵化。这包括对新兴人工智能公平实践的批判，这些实践仍然在强加默认范式。最后，我们将我们的理论应用于通过多层次优化和关系学习构建自创生身份的方法。尽管这些想法引发了许多开放性问题，但我们设想，机器能够将人类身份表达为一种永恒变化的关系，这将带来无限的可能性。

关键词

算法公平性、身份理论、社会建构、身份系统

ACM 参考文献格式：Christina Lu、Jackie Kay 和 Kevin R. McKee. 2022. 颠覆机器，波动身份：重新学习人类分类。FAccT '22 会议论文集，2022 年 6 月 21 日至 24 日，韩国首尔。ACM，纽约，美国，11 页。
<https://doi.org/10.1145/3531146.3533161>

1 引言

如今，与绝大多数技术系统互动时，其底层人工智能模型都会构建一个关于你的表征。这些表征的用途范围很广，从相对良性的（例如，优化推荐系统，为你提供最佳广告、视频、歌曲或搜索结果）到更为恶劣的（例如，通过计算累犯率来协助联邦法官，以及进行定向监控）。无论哪种情况，这些系统所使用的表征工作模型都基于同一个技术。

系统由有缺陷的简写构成，这暴露出人们缺乏对身份本质的批判性思考。

人工智能研究的默认范式继承了后笛卡尔经验主义的思想，而这种思想至今仍根深蒂固于许多科学研究中。该范式认为，人类身份由一些陈词滥调构成：它由固定不变的本质属性组成。统计机器学习的基本原则要么需要预先存在已标记数据的类别（在监督学习中），要么需要在训练数据集中创建此类划分（在无监督学习中）。在将身份转化为数据的过程中，任意的方面被归类到离散的、通常是互斥的类别中。这类模型默认身份在不同情境下是固定的：整体上是静态的。它们认为身份是本质性的——它具有某种内在的、自包含的、真实可靠的特质。这些概念在数学上简化了表示问题，但却无法忠实地反映身份在人际交往中的运作方式。当一个人被系统表示时，身份的各个组成部分都被扁平化了。

当然，技术抽象本质上就是抽象，但我们认为，绝大多数人工智能从业者用来捕捉身份的简化方法直接阻碍了其效用，并通过固化现有规范，在个人和社会层面造成持续的伤害。模型要想发挥作用，一定程度的抽象是必要的，但这种对身份的扁平化处理却剥夺了其应有的价值。在人类社会中，身份可以用于：相互理解的基础、一种表现形式、向群体发出接纳信号、支配与服从的标签，以及在人群中识别自我。最重要的是，身份是一种不断变化的关系。对机器而言，人类身份的价值在于它能够融入问题的有效模型中。这些现有的抽象不仅不准确，因而预测能力有限，而且这些模型还会影响社会对身份的认知，并可能造成伤害。糟糕的建模会削弱算法在社会环境中应用的能力，并导致其对噪声做出错误的解读。无论它输出什么预测，都会基于错误的信号对个人做出指导，从而加剧现有的不平等并制造新的不平等。如今，随着此类模型的大规模部署，无意的危害会在人机反馈循环中不断扩散。在进行更深入的分析之前，我们必须将人工智能的研究和应用置于晚期资本主义的语境中。当今最具影响力的研究源于政府、产业界和学术界之间密不可分的联系，主要集中在全球北方国家。而应用，则是研究的必然结果。追溯任何研究目的，迟早你会感受到资本的脉搏：市场和股东对私营企业的要求，以及在全球化经济中参与帝国主义斗争的民族国家。这使得它们之间的关系变得复杂。

*两位作者对本研究的贡献相同。

允许出于个人或课堂使用目的，免费复制本作品的部分或全部内容，但前提是不得出于盈利或商业目的制作或分发副本，且副本必须包含本声明和首页的完整引用信息。必须尊重本作品中第三方组件的版权。所有其他用途，请联系所有者/作者。FAccT '22，2022 年 6 月 21 日至 24 日，韩国首尔 © 2022 版权所有/作者所有。ACM ISBN 978-1-4503-9352-2/22/06。
<https://doi.org/10.1145/3531146.3533161>

如今部署的算法与我们自身之间存在着一种不对称的关系。你可以称之为技术封建主义[35]或监控资本主义[42], 但无论从哪个角度分析, 这种互动最终都是一种剥削。虽然对这些系统的全面研究超出了本文的范围, 但值得注意的是, 算法与身份的互动都出于经济目的, 无论是为了塑造固定的主体、挖掘数据还是吸引注意力。这不禁令人质疑, 考虑到制造者的身份, 让当今的机器更好地掌握身份信息是否真的有益。我们认为, 更流畅地呈现身份信息并不一定等同于更高分辨率的数据; 结构上的精确性并不一定意味着可以提取更多细节。相反, 这种对机器的呈现方式可以赋予我们比现有模式更大的自主权。或许它甚至可以让成为难以捉摸、无利可图的主体。

批判理论及相关领域的思想流派提出了一种比人工智能研究中简化定义更为动态的身份理解。身份的明确定义难以捉摸, 但将其理论化为一个关系过程系统至关重要。将这些概念融入机器学习框架不仅是为了忠实于现实, 也是为了构建不会固化现有规范的系统。在第二部分, 我们将身份理论描述为一个我们称之为“自创生系统”的概念, 即一个不断演化的建构和功能过程。第三部分将对此进行论证, 该部分借鉴了来自批判性探究领域的、挑战人工智能研究中现有概念的身份理论。我们强调了保持身份矛盾的重要性, 考察了其物质性的不确定性, 并将其概念化为一系列持续迭代的事件。在第四部分, 我们将批判现有的人工智能公平性方法, 这些方法未能纳入这种本体论, 而是延续了一种离散的、静态的、本质化的身份概念。我们强调这种抽象方式带来的风险, 并使用以下三个二分法来描述身份并构建我们的分析。

(1) 离散与连续; (2) 静态与情境; (3) 本质与共建。最后, 第五节设想了一个融合这些特质的替代框架。我们概述了两种涉及多级优化和关系学习的模型设计技术方法, 然后描绘了更优系统能够实现的功能。能够表示人类社会身份动态系统的模型为我们提供了哪些可能性? 哪些偏见得以规避? 人机之间又会涌现出哪些新的反馈途径?

通过调整我们对“身份”这一概念的集体理解, 摒弃不严谨的抽象概念, 转而采用更为精确的表述, 我们希望能够减轻因我们所部署的技术框架中存在的根本性误解而造成的危害。人工智能的影响波及整个社会; 其最终走向取决于我们。

2. 身份即自创生

我们谈论“身份”时指的是什么? 我们是否将其概念化为一种贯穿世界的固定物质?

或者更确切地说, 它是我们讲述关于自身和他人的叙事? 身份认同已成为一系列适用于人的属性(种族、阶级、性别等等)的简写, 但最好将其理解作为一种行动: 认同。你认同或不认同, 运用关系术语将自己置于被分类的人群之中。重新诠释为一种行动, 我们便可追问: 认同于什么? 认同在想象的领域运作, 是一个区分的过程, 涉及将幻想层层叠加于被认同的主体之上。你的幻想, 他们的幻想, 你对他们幻想的幻想, 他们对你幻想的幻想。这是一个非决定性的、情境敏感的事件, 但它最终会沉淀成一种分类模式, 一种复杂的分类, 一种“细节与抽象之间必要的协商”[6]。我们集体的分类成为一种萌芽的地形, 无形且不断变化, 却依然具有强大的影响。

人们很容易认为, 在这些幻想层层之下, 存在着某种与之相关的实质, 认同的本质可以被挖掘出来。但这种本质与认同过程本身一样, 都是不确定的: 不存在一种固定不变的特质, 能够贯穿所有人、所有时期的所有认同。真正持续对话的, 是认同过程中各种想象的交叠。在集体层面上, 这些交叠凝结成用于认同的社会规范, 朱迪斯·巴特勒在《性别麻烦》[8]中称之为“文化可理解性”。我们所认知的身份实质, 本身就是对身份构成要素的幻想不断展开的产物。当对任何被感知到的身份实质进行仔细审视时, 这种递归显而易见。虽然身份实质往往是虚幻的, 但其后续影响却是不容置疑的物质性。无论从哲学还是心理学的角度来看, 身份都是人类经验不可或缺的一部分。它与政治的关联在于其作为权力载体的不可化约性: 它如何调和主体间的关系。所有被感知到的差异, 无论是否确凿, 都可能造成排斥和权力不对等。

1972 年, 生物学家温贝托·马图拉纳和弗朗西斯科·瓦雷拉提出了“自创生”(autopoiesis)一词, 用来描述一个能够自我复制和维持的过程网络, 旨在捕捉活细胞的自包含化学特性[31]。这样的系统能够不断地再生自身的组成部分和组织, 实现产生它们的过程本身。通过将身份概念化为一个包含其构建和功能的自创生系统, 我们可以凸显其过程的自我强化循环性和永恒运动。因此, “构建”指的是身份在话语和心理层面形成的过程。“功能”指的是身份在内部和人际层面被使用的过程。每组过程都相互影响, 构成对方的组成部分; 两者可以在同一社会互动中同时存在。这种抽象方法能够解释定义身份时固有的矛盾。女权主义和酷儿理论对于身体如何融入身份认同存在争议, 但这种本体论并不试图精确定位这种建构或功能的来源。相反, 它描述的是概念形成的过程。

将身份可视化为一个自生成的交互系统, 揭示了其演化的能力。由于它由反馈回路构成, 任何关于身份功能或构建方式的规范一旦受到扰动, 都可能波及整个网络。社会漂移是可能的。然而, 机器学习对身份的抽象……




图 1：人类（双向）与机器（单向）身份认同过程图。

这并非一个自组织系统，而是一个单向系统：人类身份的构建完全取决于其对算法的效用（图 1）。随着弱人工智能成为日常生活中无处不在的对话者，这阻碍了身份在社会中演化的过程。所有既有的范畴都被物化。如果不对该领域的身份进行批判性的重构，权力等级制度也将以同样的方式固化。

3. 关于身份的理论探讨

将身份理论化为建构与功能的反馈回路，可以清晰地揭示当前人工智能领域对身份理解的不准确性。在第四节批判机器学习方法之前，有必要先阐明并论证围绕这一本体论提出的主张。本节将借鉴巴特勒、斯图亚特·霍尔、凯伦·巴拉德和贾斯比尔·K·普阿尔等众多理论家的观点（此处列举部分），来佐证身份作为一种自创生系统的概念。我们将着重阐述身份研究方法中固有的矛盾，探讨如何理解其不确定的物质性，并描绘其过程的循环迭代特性。

3.1 保持矛盾

围绕身份认同的理论构建本身就充满矛盾，也正是这些矛盾使得理论构建如此难以应对。在论文集《文化身份认同问题》的导言中，斯图亚特·霍尔提出疑问：身份认同为何能在各个学科中持续保持相关性，即便它已被批判和解构数十年之久？他指出，理论家们对身份认同采取的解构方法，并非用“更真实”的概念取代其核心概念，而只是将其标记为不再适用。然而，由于没有用积极的概念取而代之，我们别无选择，只能继续以解构的形式使用它们。也就是说，“看似否定它们的界限，却又悖论地允许它们继续被解读” [19]。身份认同的概念存在于“逆转与涌现”之间的过渡空间，霍尔将其描述为“一种无法用旧方式思考，但又无法用旧方式思考某些关键问题的观念”。要批判我们所处的社会秩序，我们就必须做出这种妥协。

女权主义理论一直在努力应对这一悖论，即怀疑的诠释学被投射到定义其主体及其解放工具的范畴之上。在《性别麻烦》一书中，巴特勒指出，“女性”指代共同身份的假设受到了焦虑的质疑，但却极难被取代[8]。性别不可能是一个稳定的能指。

因为我们无法将它从其产生的语境中剥离出来。但与此同时，人们又渴望假定存在一个统一的女权主义主体，以此作为团结的基础。巴特勒认为这与女权主义的目标背道而驰，并质问道：“将‘女性’这一范畴构建为一个连贯稳定的主体，是否无意中对性别关系进行了规制和物化？”的确，这种范畴的效用因其所作出的规范性规定以及任何对其定义进行修改所隐含的否定性限制而受到限制。但分类是不可避免的，我们不妨追问，如果没有一个可以固定的主体，我们又该如何理解仍然存在的歧视呢？在“当代权力场域”之外，不存在中立立场，也无法拒绝强加于身的事物。巴特勒指出，一个独立的范畴实际上会削弱任何代表权的主张，只有当“‘女性’这一主体在任何地方都不被假定存在”时，它才有可能存在。只有推迟对身份类别的任何定论，我们才能批判那些使身份类别停滞不前的规范结构。

作为主体，维系自身身份认同也必然包含矛盾。霍尔将身份认同描述为一种认知过程，它根植于某种共同的起源或共享的属性，是一种最终总是带有条件性的符号实践。身份认同建立在投射和理想化之上，因此必须承认，“身份认同从来都不是统一的，在后现代时期，它日益碎片化和破碎；它从来都不是单一的，而是在不同的、往往相互交织甚至对立的话语、实践和立场之间构建而成的。”他认为，身份认同只有通过差异才能发挥作用，“因为它能够排斥、遗漏、将‘外部’、贬低。”对霍尔而言，摆在眼前的任务是进行理论化：

[...]个体作为主体，通过何种机制认同（或不认同）他们被召唤到的“位置”；以及他们如何塑造、风格化、生产和“表演”这些位置，以及为什么他们永远不会彻底地、一劳永逸地这样做，有些人甚至永远不会这样做，或者处于一种持续的、对抗性的过程中，与他们面对和规范自身的规范或规制规则进行斗争、抵抗、协商和适应。

因此，身份认同要求我们阐明将我们固定为主体的各种话语和实践，与使我们能够发声的过程之间的“缝合点”。我们依附于话语概念和能指，同时又明白它们始终是不充分的表征。这一系列“自我建构、认知和反思”的实践，在世界中塑造了被认同的自我。

3.2 重要性和不确定性

在探讨构成身份的各种过程的特征之前，我们必须将物质置于其系统之中。人们很容易想象存在一种单一的实质，某种不容置疑的“一体性”基础，以此来赋予偏见并加以利用，从而构成任何特定身份的范畴边界。这种所谓的特征可以是物质性的，也可以是话语性的（想想……的紧迫性）。

女权主义者试图阐明某种普遍存在的父权统治结构，但我们可以想象这种结构的必要性。然而，巴特勒驳斥了这种论调，并认为这种凝聚力与任何群体的解放愿望背道而驰，反而形成了一种固化约束的封闭状态。最终留存下来的并非本质主义的身份概念，而是一种策略性的身份概念。

但这个体系中是否存在某种物质性因素？答案是肯定的——社会互动会产生物质效应，这些效应会不断扩散，包括影响身份认同的形成。霍尔认为，自我并不存在一个稳定的核心，而是一个持续的生成过程。也就是说，在那些拥有共同历史背景的人们所持有的叠加的自我认知中，并不存在隐藏的真正的“自我本质”。因此，问题在于：“如何在生成而非存在的过程中运用历史、语言和文化的资源：与其说是‘我们是谁’或‘我们从哪里来’，不如说是我们可能成为什么，我们如何被呈现，以及这如何影响我们如何呈现自己。”正因为身份认同部分是想象的、象征性的，是通过话语建构的，所以我们必须理解它形成的路径：它得以产生的历史和政治制度。

霍尔所构想的“一个表达、缝合、过度决定而非归纳的过程”，可以用机器学习的术语来解释身份认同。这种生成过程始终是一种不适的契合，它通过与话语幻想的不完美依附而得以实现。身份认同，即生成，是一个关系性的过程，我们试图通过这个过程来解析和组织世界，并将自身定位其中。换句话说，它是模式识别，是对信息的推断，是围绕我们设定和被强加于我们的工作定义而形成的连贯性。这里的分类是矛盾的，且带有中立的意味；这个过程本身并无害处。分类，即命名，即使之可见，正是保护我们免受“无结构暴政”[16]的保护。但每一个类别都会强化一种观点，同时抹杀另一种观点。在《梳理事物：分类及其后果》一书中，杰弗里·C·鲍克和苏珊·利·斯塔尔认为，分类是人类的本能，而且这种分类既无形又不可避免[6]。有些分类通过制度和官僚机构正式确立，有些分类则存在于我们潜意识中。关于这些分类，关键在于探究以下问题：“谁制定了这些分类？谁又可以改变它们？它们何时以及为何变得可见？它们如何传播？例如，针对浴室柜等特定空间而产生的本地化分类，与由医疗诊断、政府监管机构和制药公司产生的商品化、复杂且昂贵的分类之间，存在怎样的关系？”我们进一步追问，我们头脑中那些可塑性强的身份分类与精心设计的机器学习模型所设定的分类之间究竟存在怎样的关系？当前的任务并非彻底消除分类，而是仔细审视那些构建并维系分类形式的结构。正如鲍克和斯塔尔所言：“我们需要一幅关于事物分布的地形图，例如歧义的分布；分类系统相互交汇的动态过程——一种板块构造而非静态地质学。”“

在分析范畴体系时，鲍克和斯塔尔也强调了将过去视为不确定状态的重要性，并将其作为一种方法论实践。也就是说，对过去的认知会不断地受到“历史当下”的修正。

这种不确定性对于理解人类关于身份的概念与算法关于身份的概念之间的差异至关重要。巴特勒解构了性别的决定论虚构，这种虚构将身体视为文化概念铭刻其上的“被动媒介”。但身体并非被动的，许多女性主义理论致力于表明，用于理解性别的参照框架，以及批判性别的语言本身，都应该受到质疑。巴特勒认为：“作为一种变化且受语境影响的现象，性别指涉的并非一个实质性的存在，而是文化和历史特定关系集合之间相对交汇点”[8]。任何关于性别和其他身份的概念，都始终相对于决定这些身份的变幻莫测的过程而言，并且与这些过程密不可分。

那么，我们究竟能发展出怎样对身份物质性的不确定理解？我们又该如何既接纳又批判身份进程所依赖的物质？凯伦·巴拉德在《后人类主义表演性：理解物质如何变得重要》[2]一书中指出，将物质性融入话语体系至关重要。她批判了理论家们在概念化话语力量时所采取的过于表征主义的方法，并提出了一种关系本体论作为替代方案。这种“能动实在论”框架与我们关于身份作为自创生的概念相呼应。它从根本上将现象构建为主要的本体论单元，并规定所有实体都只能通过互动而存在（巴拉德使用新词“互动内联”来暗示在互动之前不存在独立存在的实体）。在这个互动图中，可以暂时进行切割以达成局部解决方案，构建某种局部因果结构，从而使宇宙的一部分对另一部分而言变得“差异化可理解”。因此，产生这些切割的论述实践是特定的边界构建行为，它们允许理解，但却不声称对持续动态的整体拥有任何权利。这一框架既包含物质的多样性，也包含其不确定性。机器学习算法在网络中产生这种切割以理解身份，但却暗含着建立一种固定物质和一种确定性处理方式的诉求。此类模型不应被视为一种普遍化的项目，而应假定其目的实际上构建了其支撑的物质性。

3.3 身份作为事件和迭代

为了最终阐明机器学习在身份识别方面的不足，我们将整合之前提及的两个特征：身份作为事件，以及由此延伸的身份作为迭代。在《我宁愿成为赛博格也不愿成为女神》一文中，贾斯比尔·K·普阿尔（Jasbir K. Puar）建议用集合理论的概念来补充交叉性理论[39]。她关注的并非金伯莉·克伦肖（Kimberlé Crenshaw）提出的交叉性概念[12]的“形成性、生成性和必要性干预”，而是在新自由主义将差异主流化的不断变化的语境下，运用交叉性概念的有效性。“就像多样性的语言一样，交叉性的语言，其运用本身似乎在很大程度上取代了交叉性分析。”它要求我们构建一个主体，通过“无限地增加排斥”来提供一个恰当的、被他者化的主体。普阿尔广泛借鉴了那些脱离主体构建的学者的观点，并提出了……

该集合体作为交叉性所产生的网格的增强框架。

“集合”（assemblage）这一概念借鉴于吉尔·德勒兹和费利克斯·加塔利的著作，它更强调模式关系的集合，而非最终的排列方式[13]。集合并非构建一个固定的常量来对比各种变体，而是“凸显‘变与变’，从而凸显身份的事件性”，而非任何常量。将身份分析为集合意味着要特别关注权力与情感，同时也模糊了身份构成要素的界限。例如，普阿尔运用集合的视角，重新解读了克伦肖关于十字路口车祸的案例，以及布莱恩·马苏米关于家庭暴力的事件[30]：

意义（signification）与重要性（significance）（感觉、价值、力量）之间的区别被强调。关注点在于关系模式——并非实体本身，而是它们彼此排列的模式。空间中的位置本身未必改变，但强化的关系赋予了实体新的能力。[...]一种潜能感，一种生成感。“一切皆有可能。”这是一个去地域化的时刻，一条逃逸线，某种无法立即掌控的东西——“一切都悬而未决”，而且确切地说，空气中充满了可能性。交叉身份发挥作用，因为（白人）男性总是被意识形态地编码为更容易诉诸暴力。最终，袭击发生了：手击打面部。逃逸线被重新地域化，向前进入社会脚本，一种生成状态的终结，被引导至另一种组合。

身份被重新构想为一个事件，它包含了促成其形成的各种力量和关系模式；构成这一场景的所有对象，无论人还是其他，都处于互动之中，彼此紧密相连。身份作为一种事件、一种集合体，弱化了主体性，从而允许进行一种能够应对多重关系及其在时空中持续运动的敏锐分析。

由此延伸，身份并非仅仅作为一种事件而发生；它是一种反复发生的事件。巴特勒在《身体的重要性》一书中阐明了其“表演性”的概念，即性别是一种“行为”[9]。表演性并非简单地等同于表演，而是“必须置于可重复性的过程中才能理解，即规范的规则化和约束性重复。[...]这种可重复性意味着‘表演’并非单一的‘行为’或事件，而是一种仪式化的生产，一种在约束下反复出现的仪式。”这里最关键的要素是递归性，即即时的反馈循环。表演性身份的产生总是伴随着一种对其加以约束和修正的回应。在认同的过程中，主体接受某些规范，并渴望其他规范；巴特勒将表演的这一方面称为“引用性”。然而，正如霍尔所描述的，认同始终是一种不匹配：“一种过度决定或缺失，但绝非恰当的契合，一种整体性。”

“这种迭代过程既强化又动摇了它所与之互动的身份概念。”

这正是人类身份运作方式与机器学习模型处理身份方式之间的根本区别所在。在人类社会中，身份的颠覆，以及所有有意识或无意识的行为和互动，意味着任何被构想的“身份”都处于永恒的流动之中；自然漂移必然发生，也确实发生。所有涌现的范畴，如同既有的仪式沉积，都可能被集体侵蚀并呈现出新的形式。构成身份的关系，正如我们所描述的建构与功能，远比简单地用这些术语来概括要丰富和复杂得多。然而，这种抽象却揭示了机器学习的关键缺陷。在机器学习中，“身份”的严格指称形式完全由其为模型提供的任何目的所决定，除此之外别无其他（甚至无需探究该目的本身）。对于算法而言，从建构到功能的闭环并不存在，它对身份的任何预设都无处申辩。其训练数据中用于构建身份的离散范畴和形状无法演化、迭代或颠覆。机器对身份的理解是：静止的、决定论的，以及作为存在的经验真理属性。任何关于模型局限性或为使模型有效而采取的简化方式的脚注都无法弥补人工智能在我们生活中无处不在时可能造成的危害。当这些与我们经验对话的媒介冻结了身份的流动动态时，这意味着什么？我们将被强加哪些无法改变的指令？不仅现有的身份概念，而且它们所滋生的权力结构，将会发生怎样的物化？人工智能研究领域需要对身份进行彻底的本体论转变。在接下来的章节中，我们将对现有的涉及身份的公平技术进行批判性回顾，并粗略勾勒出这种转变可能的样子。

4 人工智能公平性的局限性

将身份重新思考为一个自生系统，并对其进行形成和功能上的阐释，凸显了其循环本质。相比之下，机器学习系统则强化了一种单向关系：类别的形成和固定取决于它们对模型的效用。人工智能公平性研究者们提出了许多善意的技术方案，旨在减轻偏见并保障受保护群体的平等权利。然而，他们对身份的抽象化为构建更公平的系统奠定了脆弱的基础。在本节中，我们将通过提供一些违背我们关系身份理论的实例，来批判人工智能公平性中关于身份的本体论假设。我们将基于上述理论，从三个二分法的角度来组织我们的评估。

4.1 离散与连续

许多人工智能公平性方法都假定身份是离散的，例如使用二元性别[11]或互斥的种族类别[29]。这与身份的连续表示相悖，我们可以将身份想象成浮点值。即使在使用连续输入的系统中，预测属性（暴力犯罪率）也被二值化为 0（犯罪率的第 30 百分位数）和 1（犯罪率的第 70 百分位数），从而将问题简化为分类问题[25]。当身份在一个复杂的连续空间中运作时，离散化意味着抹杀。性别并非二元的，而是一种不断变化的论述行为。

多种族人群并非单一类别，将他们混为一谈是一种有害的疏忽。此外，即使是同一种族“类别”的人，也会因肤色歧视而遭受不同程度的歧视。就性取向而言，金赛量表将性取向反映为一个连续谱，而非异性恋和同性恋的二元对立（克莱因方格表和斯托姆斯量表等多维系统进一步丰富了这一概念[41]）。

这种缺乏渐变性的情况通常是由于所选模型的局限性造成的，例如，当选择分类（输出离散类别）而非回归（输出实值预测）进行预测时。在 Ionescu 关于基于种族的同质婚配的研究中[23]，由于所使用的基于代理的模型只能处理二元特征，种族类别被简化为黑人和白人。即使是分析性别分类系统中肤色歧视的 Gender Shades 研究，也选择了离散类别来标记肤色，而不是使用连续变量[7]。在系统设计过程中，包括数据集收集和管理阶段，可以在模型约束生效之前，随时决定是否对身份进行离散化。ProPublica COMPAS 数据集旨在分析累犯预测中的种族偏见，它将种族分为六类：黑人、白人、西班牙裔、亚裔、美洲原住民和“其他”（该类别描述了 8 万名被告中的 343 人）[29]。

支持离散化的论点是：人们常常对社会身份做出绝对的判断，那么机器为何要例外呢？事实上，多种族人群在人际交往和系统层面都常常被视为单一种族，2019 年的一项研究将这种现象称为“单一种族规范性”[15]。然而，人类的信念终究是可塑的，而机器学习系统中预设的类别却并非如此。当机器推理指导行动时，离散类别的风险便会显现；毕竟，模型的部署是为了被使用。低维离散预测只能产生简化的行动，而这些行动在实际情境中可能并不成比例。以二元化的暴力犯罪风险率为例，如果预测结果决定是否向某个社区增派警力，那么那些处于风险阈值边缘的人群将尤其不堪一击，面临更高的误捕率和警察暴力执法风险。任何基于预测的警务启发式方法都会形成一个反馈回路，加剧监禁不公，但这仅仅揭示了离散分类造成的其他危害。使用实值变量可以解决部分问题，因为它们允许存在差异的渐变。然而，它们并不能完全满足身份的自创生模型。连续值无法捕捉身份的动态性。即使将肤色置于连续统上，肤色也无法决定我们对某个种族类别的认同程度。成长经历和文化背景影响着我们与种族的关系及其认知（例如被收养者、移民和多种族人士）。我们会根据所处环境（例如工作场所、家中、朋友聚会或街头）在语言和行为上进行语码转换。事实上，这种现象存在于身份的许多方面。究竟有什么方程式能够捕捉到“一个人有多黑”或“一个人有多女性化”等社会复杂性呢？这些问题的答案，即便能够回答，也会因情境而异。

4.2 静态与上下文

静态身份是指身份在时间上保持不变，不受数据中其他变量（是否可观察）的影响。与之相反，将身份理解为情境性的则承认其会随时间和空间而变化。为了对比身份的连续性和情境性，我们来看一个虚构的例子。爱丽丝被贴上了“异性恋”的标签，但实际上她认为自己“基本是异性恋”：这种连续性特征在大多数分类中都被离散化了。与此同时，爱丽丝的同事鲍勃在工作场所调查中将自己的身份登记为异性恋，却在约会软件上只寻找同性伴侣，因为他不想在办公室公开自己的性取向。现在，假设鲍勃的雇主提供的保险公司部署了一个机器学习系统，该系统会收集大量匿名化的雇主数据以及员工的个人网络浏览历史记录。或许该系统的设计者想要检测员工的性取向，因为这是一个受保护的属性，他们希望确保像鲍勃这样的人能够获得公平的结果。那么，人工智能公平性框架中是否存在能够解释鲍勃的身份随情境变化的因素呢？

尽管机器学习的一些工具能够处理上下文和可变性，但在人工智能公平性中，身份标签通常被视为静态的。在具有影响力的个体公平性、群体公平性以及诸如子群体公平性和交叉公平性等衍生框架中，受保护的属性对于所有个体而言都被视为静态的。作为一种解决方案，反事实公平性被提出，旨在将因果上下文纳入公平性分析。在这种分析中，反事实推理可以推断可观测因素对数据集中其他变量的影响。通过构建影响可观测变量的潜在变量的有向无环图，推理过程通过干预（即用不同的值替换潜在变量）来识别原因[28]。然而，关于反事实公平性如何未能准确反映身份动态性，存在诸多批评。Kohler-Hausman 认为，使用因果推理框架来检测种族主义会将种族完全简化为表型，忽略了内在经验和社会塑造的相互作用[27]。Kasirzadeh 等人。[24] 提出了类似的批评，并建议系统设计者考虑因果图中身份类别的语义和本体论起源。在 [22] 中，Hu 指出了将社会类别表示为因果图上的节点，而不是表示为密集且不断变化的关系网络中的区域这一本体论问题。这些都是我们关于身份作为自创生系统的理论的推论。我们通过承认情境身份来提出补充性的批评。反事实公平不允许身份随情境而变化，而是将具有不同特征集的个体进行比较，以此作为彼此结果的反事实证据。在这种方法中，干预是通过生成具有反事实身份的虚构个体来实现的。然而，在反事实公平模型中，同一个个体在不同情况下会展现出不同的身份特征。这种细微的差别会对公平结果产生影响。事实上，库斯纳在《反事实公平》的补充材料中强调，受保护属性对决策的影响依赖于跨个体的干预，而非同一个体内部的干预。此外，处理情境并不能完善系统对身份的理解。仅凭上下文敏感性就允许标签可变。

但它是确定性的，在这种确定性的情境中，一组固定的条件可以改变情境变量。然而，一个不不断修正其构建和功能循环的系统无法满足我们对身份过程的理论。认识论问题仍然悬而未决。谁来决定数据集中包含哪些实体和能指？构成模型身份概念的符号是如何组合的？假定存在一个既定事实的危险是什么？

4.3 本质性与共建性

机器学习系统默认其数据中的符号反映了所代表实体的固有属性。预测、推理和计算都在数据集和模型设计所设定的僵化符号学框架内运行。当系统包含身份标签时，它会将人的分类解释为可知的、客观的、本质性的真理。这与共建理论形成对比，后者将身份视为一种持续的、不确定生成的互动过程。离散简化引出了一个问题：“一个人的身份是否可以存在于一个连续的谱系中？”静态简化引出了一个问题：“一个人的身份是否可以随时间和空间而变化？”而本质简化则进一步追问：“一个人的类别符号究竟代表了什么？又是从谁的视角出发的？”

本质主义假定身份是一种与生俱来的属性，它捕捉了主体的“本质”。我们可以将机器学习中的本质主义与贯穿于不公平医疗[37]、优生学[10]以及殖民权力和规范强化[34]的殖民科学传统联系起来。在《来自机器的真相》一书中，Keyes 等人提出了一个案例研究，说明假设自闭症和同性恋是由先天因素造成的，如何导致数据科学驱动的研究得出错误的结论[26]。社会技术系统在其结构中包含类别，因此任何试图沿着身份轴线实现公平的系統都必然会强化这些类别的边界。这样的系统可能会对隐形边缘群体造成伤害（尽管隐形有时甚至是可取的）。此类系统还会产生长期影响，因为它们会维持一套静态的标准，而社会规范却在不断变化。消除机器学习系统在受保护特征方面的偏见是人工智能公平性研究的一个重要目标，但如果按照本质界限划分受保护类别，这些模型就有可能加剧系统性不平等。

近期研究探讨了人工智能中身份表征的认知基础。Hanna、Denton 等人[21]提出了运用批判种族理论理解算法对种族和民族进行分类的指导原则。Denton 还描述了人工智能的谱系，以正视数据集中蕴含的历史和规范[14]。机器学习中的“向上学习”实践颠覆了基本假设，将机器预测的视角转向掌握权力者的社会规范和文化背景[1]。与我们的工作类似，Hancox-Li 等人批判了特征重要性方法的局限性，并提出了基于女性主义认识论的方法来解决这些问题[20]。在他们的论述中，语境敏感性和互动式认知方式与我们关于身份是持续关系过程的理论相契合。

尽管人工智能公平领域正积极参与对监督学习和非监督学习中基本身份的批判，

强化学习中的身份识别问题尚未得到充分研究。即便如此，本质主义的趋势已初见端倪。开发与人类兼容的人工智能是强化学习中日益突出的目标，旨在训练智能体与人类进行协作交互。一些近期项目旨在通过“类型”框架来提高兼容性，在该框架中，智能体被构建为对其环境中其他智能体的类型进行建模。这里的“类型”代表一些抽象特征，用于参数化实体的行为（例如，其策略或动作分布）。对类型进行建模的目的是提高模型对新个体（包括人类）的即时适应能力。然而，这些项目并未探究“类型”的本体论意义。例如，Ghosh 等人[17]训练强化学习智能体来推断其在合作博弈中的伙伴的“真实类型”。真实类型的概念对于人工智能体来说可能是合理的，因为它们可以用特定的属性进行编码。然而，如上所述，人类身份没有“真实”值——因此，基于此类类型的方法本质上是充满风险的。Nikolaidis 等人[18] [36] 采用类似的基于类型的方法来研究人机协作。作者使用无监督学习算法将行为演示聚类为不同类型，并指出“数量有限的‘主导’策略”可以解释大部分演示。该项目将人类类型作为马尔可夫决策过程中的部分可观测变量引入，从而在测试阶段改善智能体的协作。然而，类型概念仍然将人类反馈排除在模型身份构建之外。一方面，基于类型的方法可能有助于提高包容性，因为它能够推广到不同背景的人群。然而，它还有可能在不断扩展的强化学习与人机交互领域中树立本质主义的先例。

共建构主义立场认为语义范畴是流动且主观的。对于任何给定的身份范畴，人们都会根据自身情况灵活地理解其语义含义，而与自身关系无关。因此，构建一个能够发现、分类或推断“客观”身份标签，或从身份数据中得出“客观正确”结论的机器学习系统是不可能的——或者至少是不明智的。以往的研究要么忽略了这一点，要么仅仅利用这一点来批判科学技术领域的本质主义范式，而没有提出替代方案。与此相反，下一节将采取积极的态度。人类无时无刻不在进行主观分类。我们不断更新自己的抽象概念；我们持有相互矛盾的观点；我们设身处地地想象他人的经历和偏好。归根结底，我们对身份的理解是流动的，并且容易发生变化、演变和颠覆。那么，是否有可能改变机器学习模型中对身份的理解，使其保持一致呢？

5 种备选系统配置

尽管人工智能公平性领域涌现出越来越多的技术解决方案，但这些方案往往基于与它们所批判的模型相同的假设。大多数解决方案忽略了身份的循环迭代特性；相反，它们仍然假定身份由固定不变的本质属性构成。这些方案使身份概念僵化，不允许身份漂移或颠覆的可能性。对机器学习基本原理的更广泛批判与本文提出的“身份即交互”理论更为契合，但它们并未提出积极的解决方案，甚至有人声称该学科本身就与身份的模糊性存在根本冲突。

人类行为[4]。我们谦逊地承认，机器学习系统在理解身份方面存在认知局限性（正如我们人类一样）。然而，在这些局限性之内，存在着丰富的系统配置空间，而这些配置在人工智能公平性应用中尚未得到充分探索。将身份概念化为自创生（autopoiesis），包含构建和功能两个过程，也为身份系统和机器学习系统之间的交互方式提供了新的想象：系统内部的相互作用。我们向致力于人工智能公平性和身份问题的实践者提出两个挑战：（1）在机器学习系统中，我们如何才能实现从身份构建到其功能的闭环？机器如何才能……

形成允许变化、迭代和社会漂移的内在身份概念？

- (2) 当机器学习系统与身份系统整合时，可能产生哪些相互作用？以机器为对话者，可能出现哪些新的共同构建、颠覆和瓦解形式？

我们希望这些开放性问题能够激发新的研究方向，并通过提供具体的技术框架和初步的理论构想来勾勒出可能的研究方向。为了完善机器对身份的理解，我们概述了两种受第三节理论启发而提出的互补方法：多层次优化和关系学习。为了设想人机之间身份共同构建的新形式，我们最后阐述了系统内部交互的场景，在这种场景下，机器能够理解不断变化的身份。

5.1 闭环技术方法

5.1.1 自创生作为多层次优化。社会集体

构建身份概念是为了适应某些功能，但个体也会根据自身身份定义必要的功能。我们能否用计算模型捕捉这种构建与功能之间的循环互动？描述我们身份模型的一种可能工具是双层优化，其中一个模型相对于另一个模型的最优解进行优化：

$$\begin{aligned} x &= \arg \min_{x \in X} F(x, y(x)) \\ y(x) &= \arg \min_{y \in Y} f(x, y) \end{aligned}$$

双层优化方法涵盖了两种流行的机器学习框架：生成对抗网络（GAN）和强化学习中的 Actor-Critic 方法 [38]。我们分别考察了这些框架，以了解它们是否适用于身份学习，然后概述了受这些技术启发而构建的身份学习系统的结构示意图。

在无监督生成对抗网络（GAN）的设置中，目标是学习如何从输入数据集的分布中生成可能的样本。生成器网络生成候选样本来欺骗判别器，而判别器网络则将样本分类为真实样本或生成的样本。一个显而易见的身份识别应用是训练判别器将样本分类（或回归）到身份标签，并优化生成器以生成难以分类的样本。

这些对抗性的身份示例可以定性地说明那些不遵循隐性规范的特征。这种方法也体现了我们自创生身份模型的上下文流动性。随着生成器和判别器的交互，身份边界会随时间而变化。然而，这种方法需要以身份标签的形式对训练数据中的人进行监督。因此，这种方法无法颠覆机器学习中默认的身份表示。在最终的训练产物中，无法保证对身份的上下文理解。构成身份类别的特征本质上是由数据集单向决定的。或许对生成对抗网络（GAN）进行其他扩展可以更贴合我们的身份模型，但我们将这方面的探索留待未来。

在 Actor-Critic 模型中，目标是训练智能体输出一系列动作，使其在环境中随时间推移最大化奖励。策略网络生成最大化价值函数的动作，该价值函数由评论家函数学习得到。这里，价值被定义为状态/动作对的预期奖励的折扣和（取决于策略，因为它是未来动作的来源）。与对抗性模型不同，这两个目标并非相互对立，但它们的循环依赖性使得优化在实践中变得困难[18]。想象一个马尔可夫决策过程（MDP），其中状态代表一个人随时间变化的可观察特征以及他人观察到的反应，而动作则代表该人在特定状态下的身份标签。在这种情况下，策略学习类似于个体构建自身身份的过程：个体选择随时间推移认同什么，这种认同受到感知输入、他人赋予以及个人偏好的影响。评论家代表个体在特定情境下主动身份的效用。Actor-Critic 框架并不局限于离散或连续 的表示。马尔可夫决策过程（MDP）的序列特性体现了身份随时间变化的特性，而生成对抗网络（GAN）方法则缺乏这种特性。此外，参与者和评论家会根据外部和内部反馈相互构建构成身份的特征。

在这种情况下，奖励函数代表什么？一种可能的解释是，它代表个体对策略在当前情境下提供的身份标签的满意度。然而，这种方法存在一些问题。满意度是被主动测量还是建模的？如果人类参与其中，他们如何被纳入训练循环？系统将如何应对训练过程中未遇到的身份？在另一种配置中，奖励代表特定任务中的满意度。此时，身份识别成为一项辅助任务，其相关性取决于人类偏好与环境的交互方式。策略根据身份行为对当前任务的效用，结合人类偏好、人类响应甚至智能体响应，来关联身份行为。这种基于行动者-评论家方法的提议重申了在人工智能公平性方面考虑强化学习潜在用途和误用的重要性。

与上述许多系统不同，该框架避免了那些会造成偏见并限制身份认同的显式先验假设。然而，它并未解决数据集收集过程中的认知论问题、分类和表征的选择，以及身份认同中的主观位置。此外，它将身份认同视为环境的函数，而环境本身定义模糊，可能难以进行有效的操作化定义。一个能够使策略学习身份认同的环境必须同时包含偏好。

所描述的个人及其周围的社交网络。因此，在下一个设计草图中，我们将重点转向身份的关系本质。

5.1.2 关系型和主观学习。霸权力量塑造着机器学习，并反映在标准数据集和基准测试中根深蒂固的系统性偏见中。关于数据集收集过程中权力动态的案例研究，请参见 Miceli 等人 [33]。作为西方普世主义的替代方案，Birhane 提出关系伦理作为构建更公平的社会技术系统的指导原则 [3]，该系统以所有实体的相互关联为中心，并根据个体与他人的关系来定义人格。关系型思想流派包括非洲女性主义哲学、祖鲁族的 Ubuntu 传统以及道家等东方传统。它也通过尊重人类与自然的相互依存性来推动生态女性主义方法。[32] 探讨了 Ubuntu 的核心概念，以构建人工智能治理的指导框架。然而，关系性在人工智能公平系统设计中尚未得到广泛应用。

自创生身份模型本质上是关系性的：它将个体的身份置于一个不断变化的互动网络中。社交网络中的每个个体都会基于自身的经验对他人的身份产生不同的感知。那么，学习身份的关系性方法会是什么样的呢？我们可以从一个主观的身份数据集入手。我们可以要求特定社群中的个体首先描述自己的身份，然后基于他们各自的主观内在逻辑来描述其他参与者的身份。这样的数据集可以训练一个完全关系性的身份模型——该模型在构建上是主观的，但反映了每个个体为集体身份系统带来的关系。我们可以将一个监督式身份分类器与观察者的自我认同（或潜在身份嵌入空间的相关特征，具体取决于表征方式）联系起来。在包含与资源分配或分配任务相关的数据的场景中，我们可以应用算法公平性技术，根据数据集中个体对身份和保护特征的不同感知，计算出一组主观上公平的结果。这种关系的操作化对于捕捉语义网络可能普遍有用，其中意义是主观的，分类是语境性的——从对法律和道德规范的解释，到生物体的生物分类。

当然，根据定义，该模型只能推广到参与者群体的人口统计特征。正如鲍克和斯塔尔[6]所强调的，所有标准都会强化和抹杀既有的认知；不存在“不受地域限制的视角”。如果某些群体在模型部署的目的和地点方面代表性不足，那么条件模型的质量必然会下降。该模型无法超越构成其训练数据的群体的认知和偏见。

数据格式也是一个关键考虑因素。我们建议将身份信息记录为带有开放式提示的自由文本字段，而不是使用通常预先设定的、维度受限的向量来表示种族、性别等选项。如果数据集足够大，那么基于这样的数据集训练语言模型就可以生成丰富多样的身份潜在表示。

以及一个用于身份生成的条件模型。个体的外部感知特征可根据系统的应用进行定制。受其他公平性应用启发，示例包括面部照片、简历或求职申请、医疗记录（需要注意的是，在任何人类数据集中都应仔细考虑隐私问题）。回到 Hall[19]的观点，任何可观察的身份标志“永远都不是完全合适的”，它始终是对不断变化的身份图景的不完整快照。所提出的数据集将提供由其对象构成的图景的多个快照，而算法的作用是将这些快照拼接成一张关系身份图。

5.2 系统内相互作用的理论想象

除了弥合身份形成差距的技术框架之外，我们还描绘了一种我们称之为“系统内交互”的想象图景，其中涉及的系统包括机器学习系统和自创生身份系统。第二部分描述了身份如何作为自包含的循环过程而存在，这些过程大致可以简化为建构和功能。这套包罗万象的关系不仅涵盖了我们与他人的互动，也涵盖了其他一切事物。换句话说，身份的塑造不仅取决于我们周围的人，也取决于事物。广义上的技术可以指铅笔、轮子、手机或机器学习模型。由此可见，我们身处所有物体，我们用来中介自身体验的所有技术，都构成了我们身份系统的一部分[40]。然而，对身份有更深入理解的机器学习系统与其他技术之间的关键区别在于，机器学习模型也是自包含的、持续运行的系统。也就是说，即使没有我们的参与，它们也能持续地生成身份。为了更清晰地说明：当一台机器能够充分展现身份的可塑性、迭代性、循环性和关联性时，它也可能动摇并拓展身份概念。这会在社会层面造成什么影响？当机器学习系统不再是身份类别的对抗性执行者时，又会释放出哪些可能性？由机器共同构建的赛博身份集合体又会是什么样子？答案或许已经围绕着在线社区和策展算法逐渐显现，它们催生了新的人类体验形式[5]，但本文的探讨更进一步。如果/当我们的模型能够像我们一样思考身份时，我们将拥有能够揭示新的颠覆方法、重塑身份“配置”、重构我们对身份的根本概念的机器。这听起来或许像是纯粹的推测性虚构，但别忘了：身份本身也带有某种虚构的成分。

6 结论

“身份”这一有用的概念令机器学习从业者感到困惑，他们常常陷入简化抽象和扼杀复杂性的两难境地。关于身份的理论化充满了矛盾和不确定性，但将身份视为连续迭代的事件则使其变得清晰易懂。我们并不试图提出严格的规范，而是将身份概念化为一个自创生系统。我们将其理解为构建和功能的过程，这些过程是循环往复、自我强化的，同时又具有可塑性和可颠覆性；这一概念为批判性地审视身份提供了基础。

FAccT '22, 2022 年 6 月 21 日至 24 日, 韩国首尔 Lu 和 Kay 等人。

人工智能领域现有的范式以及对新可能性的设想。机器学习中常见的假设通过完全根据效用来配置身份, 并不允许相反的因果关系流动, 从而切断了该网络内部的双向关系。旨在减轻基于身份的危害的人工智能公平性技术通常也援引同样的假设: 身份由离散的、静态的和本质性的属性构成。我们认为, 这些做法抹杀了身份概念演进的要素, 阻碍了社会漂移、颠覆以及开放式重塑的可能性。

身份认同或许部分源于幻想, 但这并不削弱其影响或有效性。在第五部分, 我们提出两个引人深思的问题: 如何完善机器学习系统对身份的理解, 以及当机器成为身份系统中的伙伴而非对手时, 未来会呈现怎样的景象。我们概述了一个具有多级优化和关系学习的系统的高级示意图, 并勾勒出人机身份构建的新图景。我们鼓励所有机器学习从业者积极参与探讨这些开放性问题。随着人工智能在我们生活中日益普及, 它在我们的身份关系中扮演着越来越重要的角色。鉴于此, 我们呼吁对机器的配置方式进行根本性的重新构想。我们能否制造出固化现有身份和权力等级的机器, 还是能够帮助我们拓展变幻莫测的可能性维度的机器, 取决于我们自己。

7 致谢

感谢吴博喜提供参考文本和早期意见, 感谢 Guy Mackinnon-Little 的理论贡献和严谨的编辑, 感谢 William Isaac 的高层次指导, 感谢 Laura Weidinger 的审阅和反馈, 以及 Shakir Mohamed 的宝贵见解和领导。

8. 资金披露

作者声明无其他资金来源。DeepMind 的同事参与了稿件的审阅和批准。除作者外, DeepMind 未参与稿件的设计、撰写或投稿决定。作者声明无其他经济利益冲突。

参考

[1] Chelsea Barabas、Colin Doyle、JB Rubinovitz 和 Karthik Dinakar. 2020. 向上研究: 围绕权力问题重新定位算法公平性研究。载于 2020 年公平、问责和透明度会议论文集, 第 167-176 页。[2] Karen Barad. 2003. 后人类主义表演性: 理解物质如何变得重要。《符号: 文化与社会中的女性杂志》28, 3 (2003), 801-831。[3] Abeba Birhane. 2021. 算法不公正: 一种关系伦理学方法。《模式》2, 2 (2021), 100205。[4] Abeba Birhane. 2021. 自动化歧义的不可能性。Artificial Life 27, 1 (2021 年 6 月), 44–61. https://doi.org/10.1162/artl_a_00336 [5] Rena Bivens 和 Oliver L Haimson. 2016. 将性别融入社交媒体设计: 平台如何为用户和广告商塑造类别。Social Media+ Society 2, 4 (2016), 2056305116672486。[6] Geoffrey C Bowker 和 Susan Leigh Star. 2000. 理清头绪: 分类及其后果。麻省理工学院出版社。[7] Joy Buolamwini 和 Timnit Gebru. 2018. 性别阴影: 商业性别分类中的交叉准确性差异。在第一届公平性、问责制和透明度会议论文集 (机器学习研究论文集, 第 81 卷) 中, Sorelle A. Friedler 和 Christo Wilson (编)。PMLR, 77–91。

[8] Judith Butler. 1990. 《性别麻烦》(Gender Trouble)。Routledge 出版社。[9] Judith Butler. 2011. 《重要的身体: 论性别的论述界限》(Bodies that matter: On the discursive limits of sex)。Routledge 出版社。[10] Stephen Cave. 2020. 《智能的问题: 其价值取向的历史与人工智能的未来》(The problem with intelligence: its value-laden history and the future of AI)。载于 AAAI/ACM 人工智能、伦理与社会会议论文集, 第 29-35 页。[11] Won Ik Cho、Jiwon Kim、Jaeyeong Yang 和 Nam Soo Kim. 2021. 《跨语言翻译性别偏见的泛化》(Towards CrossLingual Generalization of Translation Gender Bias)。载于 2021 年 ACM 公平性、问责制和透明度会议 (加拿大虚拟会议) (FAccT '21) 论文集。美国计算机协会, 纽约, 第 449-457 页。 <https://doi.org/10.1145/3442188.3445907> [12] Kimberlé Crenshaw. 1989. 消除种族与性别交集的边缘化: 黑人女权主义者对反歧视原则、女权主义理论和反种族主义政治的批判。芝加哥大学法律系 (1989), 139。[13] Gilles Deleuze 和 Félix Guattari. 1988. 《千高原: 资本主义与精神分裂症》。Bloomsbury 出版社。[14] Emily Denton、Alex Hanna、Razvan Amironesei、Andrew Smart、Hilary Nicole 和 Morgan Klaus Scheuerman. 2020. 让人民回归: 挑战基准机器学习数据集。arXiv 预印本 arXiv:2007.07399 (2020)。[15] Karly S Ford、Ashley N Patterson 和 Marc P Johnston-Guerrero. 2019. 大学网站上的单一种族规范: 对多种族学生的系统性抹杀和选择性重新分类。《高等教育多样性杂志》(2019)。[16] Jo Freeman. 1972. 无结构的暴政。《伯克利社会学杂志》(1972), 151–164。[17] Ahana Ghosh、Sebastian Tschiatschek、Hamed Mahdavi 和 Adish Singla. 2020. 迈向稳健的合作人工智能代理的部署: 学习自适应策略的算法框架。载于第 19 届国际自主代理与多代理系统会议论文集 (新西兰奥克兰) (AAMAS '20)。国际自主代理与多代理系统基金会, 南卡罗来纳州里奇兰, 447–455。[18] Ivo Grondman、Lucian Busoniu、Gabriel AD Lopes 和 Robert Babuska. 2012. Actor-Critic 强化学习综述: 标准和自然策略梯度。IEEE 系统、人与控制论汇刊 C 辑 (应用与评论) 42, 6 (2012), 1291–1307。[19] Stuart Hall 和 Paul Du Gay. 1996. 文化认同问题。SAGE 出版社。[20] Leif Hancox-Li 和 I Elizabeth Kumar. 2021. 特征重要性方法中的认知价值: 来自女性主义认识论的启示。[21] Alex Hanna、Emily Denton、Andrew Smart 和 Jamila Smith-Loud. 2020. 迈向算法公平中的批判种族方法论。载于 2020 年公平、问责和透明度会议论文集, 第 501-512 页。[22] Lily Hu 和 Issa Kohler-Hausmann. 2020. 性别与公平机器学习有何关系? arXiv 预印本 arXiv:2006.01770 (2020)。[23] Stefania Ionescu、Anikó Hannák 和 Kenneth Joseph. 2021. 基于代理的模型: 评估在线约会平台干预措施以减少种族同质性 (FAccT '21)。美国计算机协会, 纽约, 纽约州, 美国, 412–423。 <https://doi.org/10.1145/3442188.3445904> [24] Atoosa Kasirzadeh 和 Andrew Smart. 2021. 反事实伦理机器学习中的应用与误用。载于 2021 年 ACM 公平性、问责制和透明度会议 (FAccT '21) 会议录。美国计算机协会, 纽约, 纽约州, 美国, 228–236。[25] Michael J. Kearns、Seth Neel、Aaron Roth 和 Zhiwei Steven Wu. 2017. 防止公平选区划分: 子群体公平性的审计与学习。CoRR abs/1711.05144 (2017)。arXiv:1711.05144 [26] Os Keyes、Zoë Hitzig 和 Mwenza Blell. 2021. 来自机器的真相: 人工智能与身份的物质化。《跨学科科学评论》46, 1-2 (2021), 158–175。 <https://doi.org/10.1080/03080188.2020.1840224> [27] Issa Kohler-Hausmann. 2018. Eddie Murphy 与反事实因果思维在检测种族歧视方面的危险性。《新世界》UL Rev. 113 (2018), 1163。[28] Matt J Kusner、Joshua R Loftus、Chris Russell 和 Ricardo Silva. 2017. 反事实公平性。arXiv 预印本 arXiv:1703.06856 (2017)。[29] Jeff Larson、Surya Mattu、Lauren Kirchner 和 Julia Angwin. 2016. 我们如何分析 COMPAS 累犯算法。ProPublica (5 2016) 9, 1 (2016)。[30] Brian Massumi. 2002. 虚拟寓言。杜克大学出版社。[31] Humberto R Maturana 和 Francisco J Varela. 1991. 自创生与认知: 生命的实现。第 42 卷。施普林格科学与商业媒体。[32] Sabelo Mhlambi. 2020. 从理性到关系性: Ubuntu 作为人工智能治理的伦理和人权框架。卡尔人权政策中心讨论稿系列 9 (2020)。[33] Milagros Miceli、Martin Schuessler 和 Tianling Yang. 2020. 在主观性和强加之间: 计算机视觉数据标注中的权力动态。ACM 人机交互会议论文集 4, CSCW2 (2020), 1–25。[34] Shakir Mohamed、Marie-Therese Png 和 William Isaac. 2020. 去殖民化人工智能: 去殖民化理论作为人工智能中的社会技术前瞻。哲学与技术 33, 4 (2020), 659–684。

颠覆机器，变幻莫测的身份：重新学习人类分类 FAccT '22，2022 年 6 月 21 日至 24 日，韩国首尔

[35] Evgeny Morozov. 2022. 对技术封建理性的批判。
<https://newleftreview.org/issues/ii133/articles/evgeny-morozov-critique-of-techno-feudal-reason> [36] Stefanos Nikolaidis、Ramya Ramakrishnan、Keren Gu 和 Julie Shah. 2015. 基于联合动作演示的高效模型学习在人机协作任务中的应用。载于 2015 年第十届 ACM/IEEE 人机交互国际会议 (HRI)。IEEE，189–196。 [37] Ziad Obermeyer、Brian Powers、Christine Vogeli 和 Sendhil Mullainathan. 2019. 剖析用于管理人群健康的算法中的种族偏见。 Science 366, 6464 (2019), 447–453. [38] David Pfau 和 Oriol Vinyals. 2016. Connecting generative adversarial networks and actor-critic methods. arXiv preprint arXiv:1610.01945 (2016).

[39] Jasbir K Puar. 2012. “我宁愿做个赛博格也不愿做个女神”：集合理论中的交叉性。 PhiloSOPHIA (2012)。 [40] Kim Sterelny. 2010. 心智：延伸还是支架式？现象学与认知科学 9, 4 (2010), 465–481。 [41] Michael D Storms. 1980. 性取向理论。人格与社会心理学杂志 38, 5 (1980), 783。 [42] S. Zuboff. 2019. 监控资本主义时代：在新权力前沿为人类未来而战。 PublicAffairs。 <https://books.google.com/books?id=IRqrDQAAQBAJ>